算法 1: 基于关键字的正样本资讯筛选算法

输出: 正样例集合 $S_1 = \{news_1, news_2, \dots, news_m\}$ 负样例集合 $S_{-1} = \{news_1, news_2, \dots, news_n\}$

算法步骤:

(1) 读取各个文件关键字:

 $S_1 = \emptyset$, $S_{-1} = \emptyset$

(2) **FOR** 每一个 *NEWS* ∈ *UNLABEL_NEWS*:

$$S_{-1} = S_{-1} \cup NEWS$$

ELSE IF *contain_mixed_key*⁸(*NEWS*, *POS_MIXED_KEYS*):

$$S_1 = S_1 \cup NEWS$$

ELSE IF *contain_mixed_key(NEWS, NEG_MIXED_KEYS)*:

$$S_{-1} = S_{-1} \cup NEWS$$

ELSE IF *contain_key(NEWS, POS_KEYS)*:

$$S_{-1} = S_{-1} \cup NEWS$$

ELSE IF:

 $S_{-1} = S_{-1} \cup NEWS$

END

¹ pos_files=['keywords_EVT.txt', 'keywords_GOV.txt', 'keywords_IDX.txt', 'keywords_VIP.txt', 'keywords_POS.txt']

 $^{^2\} neg_files = \ ['keywords_BLK.txt', 'keywords_ORG.txt', 'keywords_PER.txt', 'keywords_GPE.txt', 'keywords_NEG.txt'']$

³ pos_mixed_files = ['mixed_keywords_POS.txt']

⁴ neg_mixed_files = ['mixed_keywords_NEG.txt ']

⁵ unlabel_file: 需要标注资讯,文件格式: 每行一条资讯

⁶ 读取文件集函数,每个文件存储一类关键字。文件格式:一个关键字占一行,详见文件 keywords_EVT. txt

⁷ 判断是否含有关键字。匹配规则: NEWS (单个) 匹配到 KEYS 中一个关键字即为成功

⁸ 逻辑同 7,主要区别在关键字组成:每个关键字由'+'连接,如'黄金'+'美元',必须同时匹配到才算成功。组合关键字组成详见文件*mixed_keywords_POS.txt*